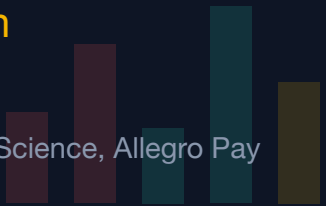
allegro PAY

POLSKI KONGRES AI · ŁÓDŹ · 28.10.2026

Odpowiedzialne AI w scoringu kredytowym

Lekcje dla każdego, kto pozwala algorytmom decydować o ludziach



Daniel Wlazło · Manager, Data Science, Allegro Pay

O mnie

Daniel Wlazło

- Menadżer zespołu Data Science w Allegro Pay, który zajmuje się modelami ryzyka
- Od 2022 r. rozwijam godne zaufania uczenie maszynowe w ocenie ryzyka kredytowego
- Interesuje mnie automatyczna ocena zdolności kredytowej, bezstronność algorytmów, kalibracja i wyjaśnialność



Allegro Pay w jednym slajdzie



- Kup teraz, zapłać później
- Miliony automatycznych decyzji kredytowych

Źródło: allegro.pl/metody-platnosci/allegro-pay.

„Dlaczego mi odmówiliście?”

Klient banku. Kandydat do pracy. Obywatel w urzędzie.

Czy Twoja organizacja potrafi odpowiedzieć:

szybko
w minutę, a nie po tygodniu analiz

prawdziwie
zgodnie z tym, co faktycznie zadecydowało

jednakowo
tak samo dla każdej osoby

Jeśli nie — to nie Ty podejmujesz decyzje. Podejmuje je algorytm, którego nie rozumiesz.

CZĘŚĆ #1

Scoring kredytowy jako poligon

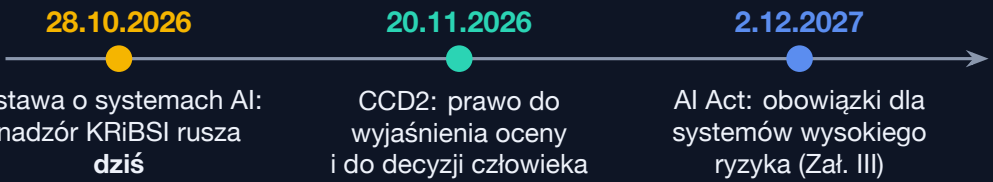
Dlaczego warto uczyć się na scoringu

Scoring to jedno z najstarszych masowych zastosowań AI wobec ludzi: decyzje są **automatyczne**, **masowe**, **ważne dla życia** i od dawna **nadzorowane**.

Obszar	Decyzja AI	To samo pytanie
Kredyt	przyznać? jaki limit?	czy umiemy to wyjaśnić?
Ubezpieczenia	jaka składka?	czy cena jest uczciwa?
HR i rekrutacja	kogo zaprosić?	czy nie dyskryminujemy?
Administracja	komu świadczenie, kontrola?	czy obywatel może się odwołać?
Windykacja	do kogo, kiedy, jak?	czy traktujemy ludzi jednakowo?

Zamień „kredyt” na swoją decyzję — reszta prezentacji nadal obowiązuje.

Kalendarz, którego nie da się przesunąć



Wysokie ryzyko to nie tylko kredyt: również rekrutacja, edukacja, dostęp do usług publicznych i ubezpieczenia.

Szczegóły prawne: poranny panel, m.in. **Kamil Giereś** (Allegro Pay). Ja pokażę praktykę.

CZĘŚĆ #2

Cztery pytania do Twojego zespołu AI

2

Cztery pytania o odpowiedzialne AI

1. Czy umiemy wyjaśnić decyzję?
Osobie, regulatorowi i sobie.

2. Czy AI myśli jak eksperci?
Czy powody mają sens biznesowy.

3. Czy jesteśmy uczciwi?
I kto o tym decyduje.

4. Czy liczby są prawdziwe?
Dziś i po zmianie otoczenia.

Żadne z nich nie jest pytaniem o algorytm. Wszystkie są pytaniami o zarządzanie.

1. Czy umiemy wyjaśnić decyzję?

Nowoczesne modele są dokładniejsze od tabel punktowych, ale „z pudełka” nieprzejrzyste.
Wyjaśnienie to nie jeden raport — to trzy różne produkty:

Osoba

Kilka zrozumiałych powodów i informacja, co może zmienić wynik.

prawo do wyjaśnienia (CCD2)

Regulator i audyt

Jak model działa, na czym się uczył, jak jest kontrolowany.

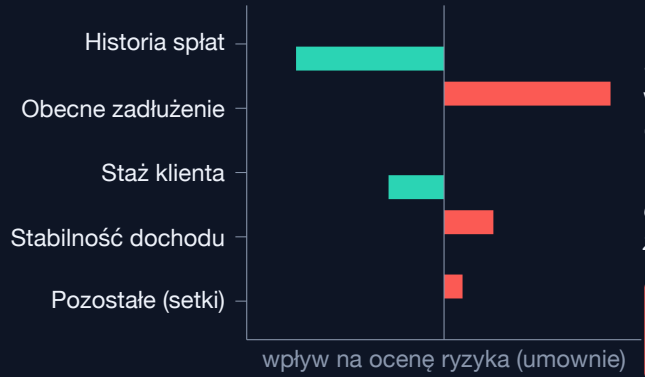
dokumentacja (AI Act)

My sami

Czy model nie nauczył się bzdur i czy wciąż działa tak, jak przy wdrożeniu.

kontrola jakości

Od setek sygnałów do kilku powodów



◄ obniża ryzyko **podnosi ►**

Setki zmiennych grupujemy w **domeny zrozumiałe dla człowieka**.

Komunikat: *„Decydujące było obecne zadłużenie. Spłata części zobowiązań poprawi ocenę.”*

Wyjaśnienie musi być **prawdziwe**, a nie tylko ładne.

Ilustracja na danych syntetycznych.

2. Czy AI myśli jak nasi eksperci?

Dokładność to za mało. Model może trafiać z niewłaściwych powodów.

Sprawdzamy kierunki

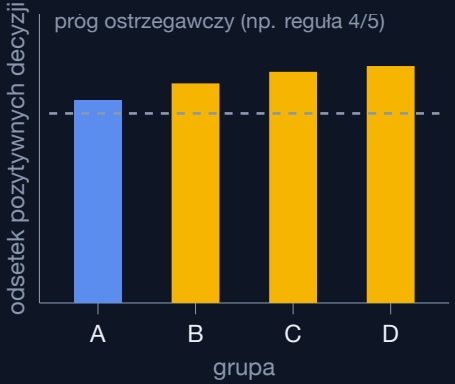
- Lepsza historia spłat ⇒ niższe ryzyko?
- Każdy nielogiczny kierunek wymaga uzasadnienia, zanim model trafi na produkcję
- To warunek akceptacji, a nie dodatek

Grupujemy ludzi według powodów

- Dwie osoby z tym samym wynikiem mogą mieć zupełnie inne powody
- Segmenty „dlaczego”, a nie tylko „ile” ⇒ lepsza komunikacja i produkty

Wyjaśnialność to nie koszt zgodności — to **wiedza o klientach**, której wcześniej nie mieliśmy.

3. Czy traktujemy ludzi uczciwie?



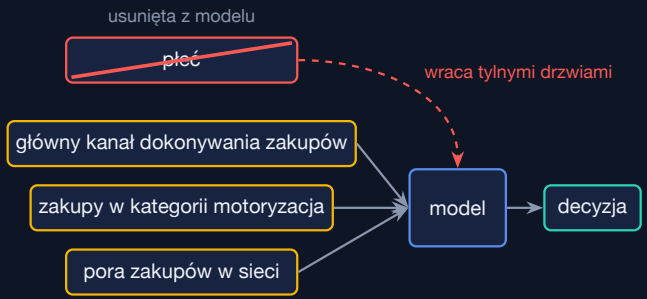
Grupy różnią się wiekiem, regionem czy historią — wyniki modelu też mogą się różnić.

Różnica to jeszcze nie dyskryminacja.
Ale każda różnica wymaga wyjaśnienia.

Mierzymy regularnie, mamy próg ostrzegawczy, a każde przekroczenie trafia do przeglądu.

Ilustracja na danych syntetycznych.

Usunięcie wrażliwej cechy nie wystarcza



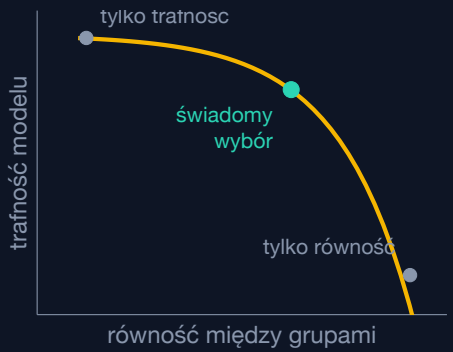
Zmienne zastępcze

Model bez informacji o płci może ją „odtworzyć” z innych danych.

Znane przypadki: algorytmy rekrutacyjne, systemy wykrywania nadużyć w sektorze publicznym.

Ilustracja poglądowa.

Sprawiedliwość ma mierzalną cenę



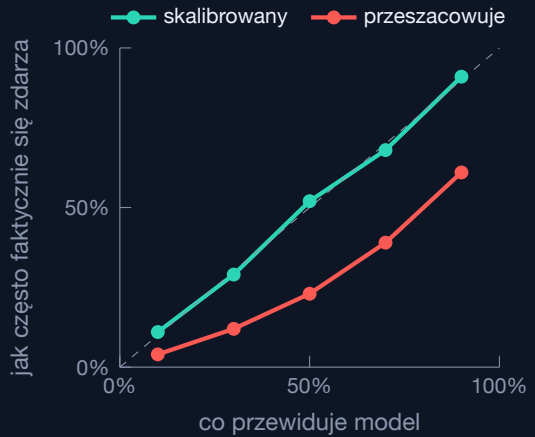
Co działa

- Mierzyć wyniki w grupach, nawet jeśli cechy nie ma w modelu
- Kilka miar naraz: dostęp, błędy, trafność
- Ocena wpływu na ludzi (FRIA) przed wdrożeniem

Wszystkich definicji sprawiedliwości nie da się spełnić naraz. To wybór wartości, więc należy do zarządu, a nie do algorytmu.

Ilustracja na danych syntetycznych.

4. Czy liczby znaczą to, co mówią?



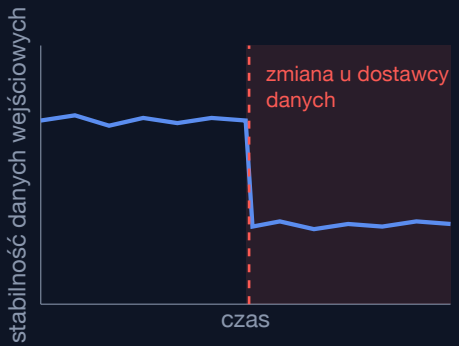
Jak w prognozie pogody: jeśli model mówi **„70%”**, to zdarzenie powinno nastąpić mniej więcej 7 razy na 10.

Na tych liczbach opieramy ceny, budżety, kolejność obsługi i przydział zasobów. Jeśli liczba jest zawyżona albo zaniżona, decyzja też jest błędna.

Model może dobrze **porządkować** przypadki, a mimo to źle podawać **wartości**. Sprawdzaj obie rzeczy.

Ilustracja na danych syntetycznych.

Odpowiedzialność nie kończy się w dniu wdrożenia



Prawdziwy przypadek: zewnętrzny dostawca danych zmienia sposób ich raportowania. **Model działa bez zarzutu** — a jego oceny z dnia na dzień się przesuwają.

- codzienny monitoring danych i wyników
- progi ostrzegawcze i ścieżka eskalacji
- analiza po każdym incydencie

Ilustracja na danych syntetycznych.

CZĘŚĆ #3

Jak to zorganizować

3

Zarządzanie modelami w praktyce

Właściciel

Każdy model ma osobę, która za niego odpowiada.

Akceptacja

Jasna ścieżka: od zespołu eksperckiego po zarząd.

Dokumentacja

Opis, jak model powstał, jak działa i co się w nim zmieniało.

Przegląd

Regularny, z jasnymi powodami do przebudowy modelu.

Ocena wpływu na ludzi przed wdrożeniem (FRIA) to nie formalność. Jej wnioski mogą i powinny zmieniać plan biznesowy.

Zgodność jako produkt uboczny dobrej inżynierii

Projekt na ostatnią chwilę
Dokumenty pisane pod audyt, rozjeżdżające się z rzeczywistością. Drogie, kruche, nieprzydatne zespołowi.

Wbudowane w proces
Dokumentacja wersjonowana razem z modelem, przeglądana jak kod. Każda decyzja zapisana z wersją modelu.

Pytanie audytora: *„Dlaczego ta osoba dostała taką decyzję 14 miesięcy temu?”*

powinno mieć odpowiedź w **minutach**, a nie w tygodniach.

Od czego zacząć? Pięć kroków

1. **Inwentarz:** gdzie AI decyduje o ludziach? Kto jest właścicielem?
2. **Test „dlaczego”:** weź losową decyzję i poproś o wyjaśnienie zrozumiałe dla laika.
3. **Pomiar w grupach:** wiek, płeć, region — nawet jeśli tych cech nie ma w modelu.
4. **Kalibracja i monitoring:** czy liczby z modelu zgadzają się z rzeczywistością co miesiąc?
5. **Decyzje zarządu na piśmie:** jaki kompromis między trafnością a sprawiedliwością akceptujemy?

Żaden z tych kroków nie wymaga nowej technologii — wymaga decyzji.

allegro PAY

Zaufanie się skaluje.
Nieufność kosztuje.

Daniel Wlazło · daniel.wlazlo@allegro.com

Dziękuję. Pytania?

